Desafío Nubimetrics para el área de datos perfiles Semi Senior

1 - Introducción

En el área de datos de Nubimetrics tenemos múltiples desafíos. Los principales son: disponibilizar la información de manera coherente, consumible y rápida a las diferentes áreas que lo requieren.

Para poder cubrir las responsabilidades de un perfil semi senior pensamos que deberías poder tener un entendimiento básico sobre el manejo de APIS; conocer ciertas operaciones sobre diferentes tipos de datos y la realización de transformaciones a través de código a las fuentes de datos existentes.

Te queremos proponer un trabajo sobre las APIs de Mercado Libre, la deserialización de un json, el manejo de un csv y la realización de 3 operaciones sobre los DataFrames.

Forma de Entrega: link a Github con el código más un documento de Google Drive con la propuesta de solución.

Te pedimos que antes de arrancar con los desafíos leas las preguntas frecuentes hasta el final

2 - Desafíos

Desafío 1: Mail

Enviar un mail con el lenguaje a utilizar: **desafio@nubimetrics.com**

Desafío 2: Interactuar con la API de Mercado Libre

Nos interesa que puedas hacer lo siguiente:

- Ir a la documentación de developers de Mercado Libre: Developers Mercadolibre
- Descargar la información en formato JSON de un Request.
- Almacenar ese JSON en una carpeta llamada con el siguiente patrón: NombreApi+Formato+año+mes. Por ejemplo: searchjson202008

Ejemplo de URL de la API: Ingresando al siguiente link que te lleva a la categoría MLA1000 podrás notar que esta API devuelve como resultado todos los productos ofertados en la categoría con nombre: Electrónica, Audio y Video.
Si bien los resultados vienen paginados solo nos interesa que bajes el json del primer offset. Si necesitan más información sobre esta API pueden consultar la documentación de Mercado Libre

Desafío 3: Deserializar un JSON

Nos interesa que puedas hacer lo siguiente:

- Ingresar a la carpeta Input Ejemplos
    - En ese lugar vas a encontrar el json: sellers.json
- Lee la información en un DataFrame.
- Seleccioná solamente los siguientes que hacen referencia a:
    - Id del site
    - Id del seller
    - Nickname del seller
    - Puntos del seller

El dataframe resultante debe ser como este:

```
+------+---------+-----------------------------+------------+
|siteId|sellerId |sellerNickname               |sellerPoints|
+------+---------+-----------------------------+------------+
|MPE   |298734964|MARIELATAQUIRE               |2           |
|MPE   |183049329|MURO8709951                  |-3          |
|MPE   |94592189 |ILLARYPERU                   |-2          |
|MPE   |520133997|ISABELLADELPOZO              |1           |
|MPE   |684964436|PHMO1747353                  |0           |
|MPE   |685079498|MELISSASUSANAARVALOSANTAYA    |0           |
|MPE   |646068761|YOMIDELGADOSNCHEZ            |0           |
|MPE   |685310649|DONATILDONATILDECORREATIMOTECO|0           |
|MPE   |685419864|VANESSAURNER                 |0           |
|MPE   |285674870|ERICKLOPEZUSMSYA             |2           |
|MPE   |685275449|DANIELARUIZRIDRIGUES         |0           |
|MPE   |48893023 |MARCELASUSAN                 |1           |
|MPE   |603331827|COVA1031117                  |0           |
|MPE   |205264135|GOBR7283790                  |1           |
|MPE   |580279940|LORDVENCEDOR                 |0           |
|MPE   |300834652|DANIELAHILARIORAMOS          |0           |
|MPE   |270322958|JHONANTHONYCAYLLAHUAMALASQU  |0           |
|MPE   |684554092|OSORIOCOLQUIJESSMIGUEL       |0           |
|MPE   |644166286|GOEL1504737                  |0           |
|MPE   |685449106|ISABELSNCHEZMEDINA           |0           |
+------+---------+-----------------------------+------------+
```

- Guardá la información deserializada en un archivo CSV con el siguiente patrón:
    - Sitio/Mes/Año/dia/**SEGMENTO**/(archivo).csv.
        - Ejemplo MPE/2020/08/28/**positivo**/[NoImporta].csv

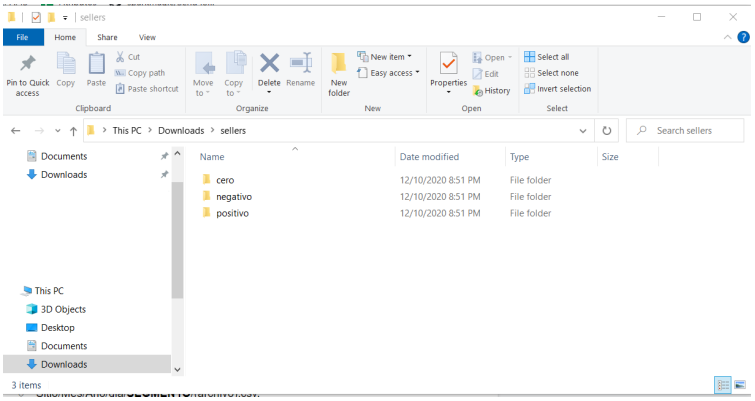

Tené en cuenta que tenés que encontrar la forma de dividir los sellers por los puntos:

- Positivos: **Positivo**
- Cero puntos: **Cero**
- Negativos: **Negativo**
- **Bonus:**
    - **Opción 1:** Spark/Scala + IntelliJ
    - **Opción 2:** Pyspark + Pycharm

Desafío 4: Parseo de un Array de Structs en un dataframe

Nos interesa que puedas hacer lo siguiente:

- Ingresar a la carpeta Input Ejemplos
    - En ese lugar vas a encontrar el json: MPE1004.json
- Lee la información en un DataFrame.
- Generes un Dataframe que tenga la siguiente estructura:
    - rowId
    - itemId
    - soldQuantity
    - availableQuantity

El Dataframe resultante debe ser como el siguiente:

```
+-----+------------+------------+-----------------+
|rowId|itemId      |soldQuantity|availableQuantity|
+-----+------------+------------+-----------------+
|1    |MPE433108265|6           |9                |
|2    |MPE434382765|6           |3                |
|3    |MPE433853177|3           |17               |
|4    |MPE419883282|15          |18               |
|5    |MPE431714651|15          |1                |
|6    |MPE438492919|0           |100              |
|7    |MPE429448587|0           |50               |
|8    |MPE439307195|0           |3                |
|9    |MPE439307251|0           |3                |
|10   |MPE437503507|0           |10               |
|11   |MPE438828260|0           |3                |
|12   |MPE439307426|0           |3                |
|13   |MPE440306037|0           |1                |
|14   |MPE439307206|0           |3                |
```

```
|15   |MPE431446248|2          |23               |
|16   |MPE439307250|0          |3                |
|17   |MPE439510012|0          |1                |
|18   |MPE439307317|0          |3                |
|19   |MPE439307286|0          |3                |
|20   |MPE439307385|0          |3                |
|21   |MPE440131689|0          |7                |
|22   |MPE432990777|1          |5                |
|23   |MPE440389411|1          |9                |
|24   |MPE421767433|4          |11               |
|25   |MPE432990779|0          |1                |
|26   |MPE432439269|2          |1                |
|27   |MPE431410374|0          |1                |
|28   |MPE430002527|1          |1                |
|29   |MPE432990781|0          |1                |
|30   |MPE432202936|0          |10               |
|31   |MPE428549066|0          |5                |
|32   |MPE428549082|1          |4                |
|33   |MPE433933924|1          |1                |
|34   |MPE432291284|2          |1                |
|35   |MPE432728801|1          |1                |
|36   |MPE433252062|2          |1                |
|37   |MPE436649728|0          |100              |
|38   |MPE427140390|10         |2                |
|39   |MPE433046443|0          |999              |
+-----+------------+-----------+-----------------+
```

Desafío 5: Agregar las visitas al DataFrame con datos de ventas.

- Utilizando el DataFrame generado en el **desafío 4** (Parseo de un Array de Structs en un dataframe) Seleccionar:
    - itemId
    - soldQuantity
- Ingresar a la carpeta Input Ejemplos
    - En ese lugar vas a encontrar el csv: visits.csv
- Lee la información en un DataFrame.
- Generar un nuevo DataFrame utilizando el deserializado y visits.csv - El Join realizado por itemId. El DataFrame resultante debe tener los siguientes campos:
    - itemId
    - soldQuantity
    - visit
- Filtrar los elementos sin ventas.

El Dataframe resultante debe ser como el siguiente:

```
+------------+------------+------+
|      itemId|soldQuantity|visits|
+------------+------------+------+
|MPE433108265|           6|   203|
|MPE434382765|           6|   170|
```

```
|MPE433853177|           3|  1034|
|MPE419883282|          15|  1772|
|MPE431714651|          15|    33|
|MPE431446248|           2|  2242|
|MPE432990777|           1|   426|
|MPE440389411|           1|   158|
|MPE421767433|           4|   746|
|MPE432439269|           2|    42|
|MPE430002527|           1|    60|
|MPE428549082|           1|   352|
|MPE433933924|           1|    49|
|MPE432291284|           2|     6|
|MPE432728801|           1|    68|
|MPE433252062|           2|    92|
|MPE427140390|          10|    81|
+------------+------------+------+
```

Desafío 6: Agregar métricas a un DataFrame.

Utilizando el DataFrame generado en el **desafío 4** (Parseo de un Array de Structs en un dataframe):

- Generar una columna con la tasa de conversión (ventas/Visitas)
- Generar un ranking por la tasa de conversión. Mejor tasa de conversión mejor posición en el ranking.

El Dataframe resultante debe ser como el siguiente:

```
+------------+------------+------+--------------+-----------------+
|      itemId|soldQuantity|visits|conversionRate|conversionRanking|
+------------+------------+------+--------------+-----------------+
|MPE431714651|          15|    33|        0.4545|                1|
|MPE432291284|           2|     6|        0.3333|                2|
|MPE427140390|          10|    81|        0.1235|                3|
|MPE432439269|           2|    42|        0.0476|                4|
|MPE434382765|           6|   170|        0.0353|                5|
|MPE433108265|           6|   203|        0.0296|                6|
|MPE433252062|           2|    92|        0.0217|                7|
|MPE433933924|           1|    49|        0.0204|                8|
|MPE430002527|           1|    60|        0.0167|                9|
|MPE432728801|           1|    68|        0.0147|               10|
|MPE419883282|          15|  1772|        0.0085|               11|
|MPE440389411|           1|   158|        0.0063|               12|
|MPE421767433|           4|   746|        0.0054|               13|
|MPE433853177|           3|  1034|        0.0029|               14|
|MPE428549082|           1|   352|        0.0028|               15|
|MPE432990777|           1|   426|        0.0023|               16|
|MPE431446248|           2|  2242|        9.0E-4|               17|
+------------+------------+------+--------------+-----------------+
```

Desafío 7: Porcentaje de Stock

Tomando el DataFrame generado en el **desafío 4** (Parseo de un Array de Structs en un dataframe):

- Seleccionar los campos:
  - itemId
  - availableQuantity
- Generar un DataFrame donde se calcule el porcentaje que tiene cada uno de esos ítems en el total.

El Dataframe resultante debe ser como el siguiente:

itemId	availableQuantity	stockPercentage
MPE433046443	999	70.3
MPE438492919	100	7.04
MPE436649728	100	7.04
MPE429448587	50	3.52
MPE431446248	23	1.62
MPE419883282	18	1.27
MPE433853177	17	1.2
MPE421767433	11	0.77
MPE432202936	10	0.7
MPE437503507	10	0.7
MPE440389411	9	0.63
MPE433108265	9	0.63
MPE440131689	7	0.49
MPE428549066	5	0.35
MPE432990777	5	0.35
MPE428549082	4	0.28
MPE438828260	3	0.21
MPE439307317	3	0.21
MPE439307426	3	0.21
MPE439307206	3	0.21
MPE439307286	3	0.21
MPE434382765	3	0.21
MPE439307251	3	0.21
MPE439307250	3	0.21
MPE439307385	3	0.21
MPE439307195	3	0.21
MPE427140390	2	0.14
MPE431714651	1	0.07
MPE432439269	1	0.07
MPE440306037	1	0.07
MPE431410374	1	0.07
MPE439510012	1	0.07
MPE430002527	1	0.07
MPE433933924	1	0.07
MPE432990779	1	0.07

```
|MPE432990781|1                |0.07           |
|MPE432291284|1                |0.07           |
|MPE432728801|1                |0.07           |
|MPE433252062|1                |0.07           |
+------------+-----------------+---------------+
```

Desafío 8: Paths 1

El objetivo del desafío es que podamos ver el desarrollo de una función. La cual, recibiendo un conjunto de strings devuelva una Lista de elementos que agrupe desde el primer día del mes hasta la fecha ingresada como parámetros inclusive. Por lo tanto, el objetivo será generar una función Path que devuelva **paths hasta el día solicitado**. El formato de la url es ficticio. Podés usar por ejemplo:

```
"https://importantdata@location/"+year+"/"+month+"/"+day+"/"
```

Ejemplo de la función en **Scala**:

```
def generateMonthlyPathList(year: String, month:String, day:String):
List[String] = {
   //Implementación de tu solución
  }
```

Ejemplo de la función en **Python**:

```
def generateMonthlyPathList(year, month, day):
   #Implementación de tu solución
    return
```

Un ejemplo de resultado. Llamada a la función:

```
generateMonthlyPathList("2021", "05", "17")
```

Resultado si imprimo a cada string en una línea:

```
https://importantdata@location/2021/05/01/
https://importantdata@location/2021/05/02/
https://importantdata@location/2021/05/03/
https://importantdata@location/2021/05/04/
https://importantdata@location/2021/05/05/
https://importantdata@location/2021/05/06/
https://importantdata@location/2021/05/07/
```

```
https://importantdata@location/2021/05/08/
https://importantdata@location/2021/05/09/
https://importantdata@location/2021/05/10/
https://importantdata@location/2021/05/11/
https://importantdata@location/2021/05/12/
https://importantdata@location/2021/05/13/
https://importantdata@location/2021/05/14/
https://importantdata@location/2021/05/15/
https://importantdata@location/2021/05/16/
https://importantdata@location/2021/05/17/
```

Desafío 9: Paths 2

El objetivo del desafío es que podamos ver el desarrollo de una función. La cual, recibiendo un string para el día y un entero para la cantidad de días anteriores devuelva una Lista de elementos que agrupe desde el día pasado como parámetro hasta los n días anteriores. Por lo tanto, el objetivo será generar una función Path que devuelva paths para **N días corridos**. El formato de la url es ficticio. Podés usar por ejemplo:

```
      "https://importantdata@location/"+year+"/"+month+"/"+day+"/"
```

Ejemplo de la función en **Scala**:

```
def generateLastDaysPaths(date: String, days:Int): List[String] = {
   //Implementación de tu solución
  }
```

Ejemplo de la función en **Python**:

```
def generateLastDaysPaths(date, days):
   #Implementación de tu solución
    return
```

Un ejemplo de resultado. Llamada a la función:"20210410", 10

```
generateLastDaysPaths("20210410", 10)
```

Resultado si imprimo cada path de la lista en una línea:

```
https://importantdata@location/2021/04/01/
https://importantdata@location/2021/04/02/
https://importantdata@location/2021/04/03/
https://importantdata@location/2021/04/04/
```

```
https://importantdata@location/2021/04/05/
https://importantdata@location/2021/04/06/
https://importantdata@location/2021/04/07/
https://importantdata@location/2021/04/08/
https://importantdata@location/2021/04/09/
https://importantdata@location/2021/04/10/
```

Desafío 10: Restaurar BBDD

Restaurar la base de datos **AdventureWorks2014.bak** que se encuentra en el sitio oficial de microsoft [AdventureWorks sample databases]

Una vez restaurada en tu cliente de base de datos deberías verla de una forma similar a esta:

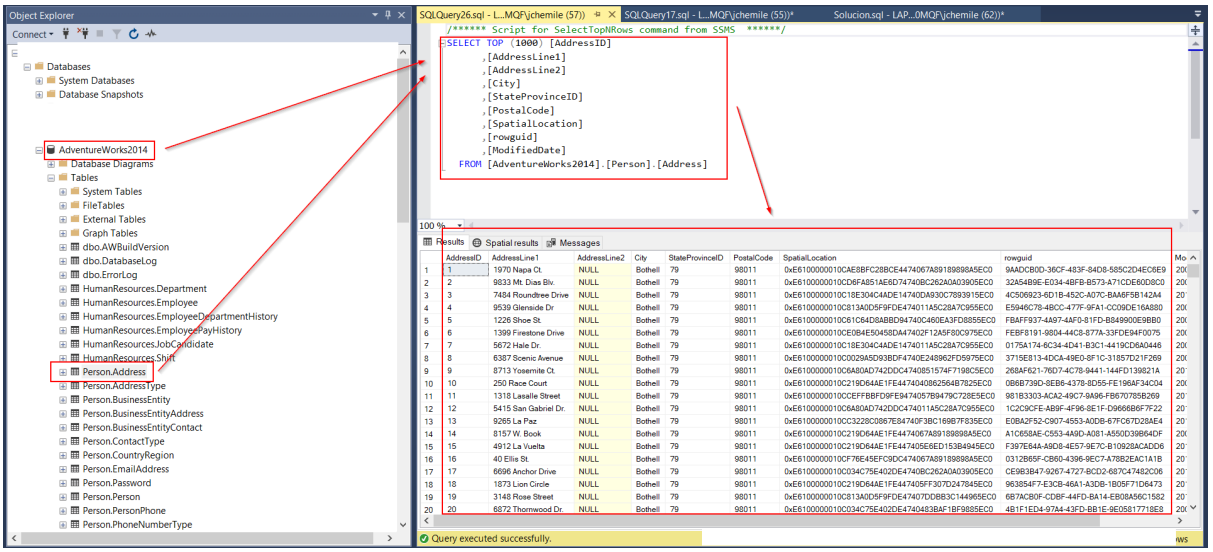

Desafío 11: SQL 1

Generar un listado con el promedio del tax Rate por país. Las tablas que se utilizaron para realizar el resultado de la consulta son las siguientes: **[Sales].[SalesTaxRate]** y **[Person].[StateProvince]**

El resultado debería ser similar al siguiente:

	country_region_code	average_taxRate
1	AU	10.00
2	CA	8.4333
3	DE	16.00
4	FR	19.60
5	GB	17.50
6	US	7.405

Desafío 12: SQL 2

Generar un listado en el que se pueda ver la **tasa de cambio** y la **tasa impositiva** por país. Sólo se deberán mostrar los países que la posean. Las métricas deberán estar redondeadas a 2 decimales. Recordá que sólo se deben mostrar aquellos resultados que tengan tanto tasa de cambio como tasa impositiva. Las tablas que intervienen son las siguientes:

- [Sales].[SalesTaxRate]
- [Person].[StateProvince]
- [Sales].[CountryRegionCurrency]
- [Person].[CountryRegion]
- [Sales].[CurrencyRate]
- [Sales].[Currency]

Y el resultado debe ser similar al siguiente:

Results Messages

	country_name	currency_name	currency_rate	average_tax_rate
1	Australia	Australian Dollar	2.09	10.00
2	Canada	Canadian Dollar	1.62	8.43
3	France	EURO	1.21	19.60
4	France	French Franc	7.37	19.60
5	Germany	Deutsche Mark	2.20	16.00
6	Germany	EURO	1.21	16.00
7	United Kingdom	United Kingdom Pound	0.73	17.50
8	United States	US Dollar	1.00	7.41

3 - Preguntas Frecuentes

1. ¿Puedo usar el lenguaje y/o framework que quiera?

Sí, podés usar el lenguaje y framework que quieras. No hay restricción de lenguajes para la resolución del problema. De todas formas, es necesario que tengas presente que en tu día a día vas a estar expuesto a código Scala. Por lo tanto, una vez dentro de Nubimetrics lo vas a tener que aprender.

2. ¿Cómo lo envío?

Link a Github con el código más un documento de Google Drive con la propuesta de solución.

3. ¿Tengo que hacerlos todos?

Sí. Al ser un perfil Semi Senior esperamos que puedas realizar todos los desafíos.

4. ¿Dónde me puedo comunicar si tengo dudas?

Si tenés una duda podés preguntar en: **desafio@nubimetrics.com**

5. ¿De verdad tengo que mandar el mail que se indica en el **desafío 1**?

No. **No envíes el mail del desafío 1**. Es para saber si se piensa antes de actuar.